

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
“КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ”
ФІЗИКО-ТЕХНІЧНИЙ ІНСТИТУТ
КАФЕДРА ІНФОРМАЦІЙНОЇ БЕЗПЕКИ

«До захисту допущено»

Завідувач кафедри

(підпис)
М. В. Грайворонський

“ _____ ” _____ 2017 р.
(ініціали, прізвище)

Дипломна робота

освітньо-кваліфікаційного рівня “магістр”

за спеціальністю 8.04030101 «Прикладна математика»

на тему «Тема»

Виконав студент 6 курсу групи ФІ-51м

Кригін Валерій Михайлович

Керівник к.т.н., Барановський Олексій Миколайович

Рецензент ,

(підпис)

(підпис)

(підпис)

Засвідчую, що у цій дипломній роботі
немає запозичень з праць інших авторів
без відповідних посилань.

Студент _____

РЕФЕРАТ

КЛЮЧЕВЫЕ СЛОВА

ABSTRACT

KEYWORDS

РЕФЕРАТ

СЛОВА

ЗМІСТ

Вступ	6
1 Теоретичні відомості	7
1.1 Попередні роботи.	7
1.2 Породжувальна модель обличчя	7
1.3 Задача	9
1.3.1 Бінарна функція витрат	12
1.3.2 Інтервальна функція витрат	13
1.3.3 Різниця моделей	14
1.3.4 Різниця параметрів.	16
1.4 Розв'язок	17
1.4.1 Бінарна функція витрат	17
1.4.2 Різниця параметрів з урахуванням їх гаусового розподілу	20
1.5 Метод Монте-Карло	22
2 Практичні результати	26
3 Охорона праці	27
Висновки	28
Перелік посилань	29

ВСТУП

Актуальність роботи.

Об'єкт дослідження —

Предмет дослідження —

Мета дослідження.

Завдання наступні:

- 1) Вивчити;
- 2) Розробити.

Практичне значення одержаних результатів.

1 ТЕОРЕТИЧНІ ВІДОМОСТІ

1.1 Попередні роботи

У даній роботі використовується породжувальна модель обличчя 3D Basel Face Model (BFM) розроблена командою Базельського університету [1]. Перший підхід, яких дозволяє отримати тривимірну модель обличчя лише за одним фото, було запропоновано Томасом Феттером та Фолькером Бланцом [2]. Вони використовували BFM та стохастичний градієнтний спуск [3], що дозволяло досягти добрих результатів за 40 хвилин з процесором Pentium III, 800MHz [4]. Згодом ті ж автори розробили та використали у своїй роботі стохастичний алгоритм Ньютона [5], яким досягли реконструкції просторової конфігурації обличчя за 4.5 хвилини на Pentium 4, 2GHz.

Пізніше студент Національного Технічного Університету України “Київський Політехнічний Інститут” запропонував та запатентував свій метод створення генеративної моделі обличчя та відновлення тривимірної поверхні обличчя за одним або кількома фото [6]. Основні відмінності полягають у тому, що задачу співставлення відповідних точок різних моделей було представлено та розв’язано в термінах задачі розмітки [7], а нові моделі обличч генеруються як зважене середнє.

1.2 Породжувальна модель обличчя

За допомогою високоточного 3D сканеру було зафіксовано 100 чоловічих і 100 жіночих облич. Це люди віком від 8 до 62 років (25 в середньому), вагою від 40 до 123 кілограмів (66 в середньому).

Щоб зважена сума обличч теж була обличчям, потрібно знайти відповідність

між вершинами моделей різних облич. Тобто, оскільки модель складається з впорядкованого набору вершин, точка, яка відповідає, наприклад, за горбинку на носі, повинна бути на одній і тій самій позиції в масиві кожної моделі. Для цього була використана модифікація ітеративного алгоритму найближчих точок ІСР [8]. Після цього достатньо відмітити опорні точки обличчя лише на одній моделі, щоб вони були відомі на всіх інших, у тому числі на похідних обличчях.

Розраховується середня модель обличчя як середнє арифметичне по всіх моделям

$$\bar{f}_v = \frac{\sum_{f \in F} f_v}{|F|}, \quad v \in V,$$

де V — множина вершин, F — множина облич, f_v — координати вершини v в обличчі f . Середня модель теж є обличчям завдяки попередньому кроку співставлення вершин.

Останній етап, який нас цікавить, це обробка даних за допомогою методу головних компонент [9]. На вході матриця, кожному стовбцю якої відповідає координата вершини, а стрічці — обличчя. На перетині f стрічки і v_i стовбця знаходиться значення i компоненти координат вершини v обличчя f

$$M = \begin{bmatrix} M_{v_x^1}^{f^1} & M_{v_y^1}^{f^1} & M_{v_z^1}^{f^1} & M_{v_x^2}^{f^1} & \dots & M_{v_y^m}^{f^1} & M_{v_z^m}^{f^1} \\ M_{v_x^1}^{f^2} & M_{v_y^1}^{f^2} & M_{v_z^1}^{f^2} & M_{v_x^2}^{f^2} & \dots & M_{v_y^m}^{f^2} & M_{v_z^m}^{f^2} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ M_{v_x^1}^{f^n} & M_{v_y^1}^{f^n} & M_{v_z^1}^{f^n} & M_{v_x^2}^{f^n} & \dots & M_{v_y^m}^{f^n} & M_{v_z^m}^{f^n} \end{bmatrix}.$$

На виході маємо дисперсії головних компонент і лінійне перетворення L коваріаційної матриці \widetilde{M} , яке робить $L \cdot \widetilde{M} \cdot L^{-1}$ діагональною.

Оскільки маємо головні компоненти, нове обличчя отримується не як зважене середнє кількох облич, а як сума середнього обличчя та вектору параметрів

x помноженого на матрицю L

$$M(x) = \bar{f} + x \cdot L.$$

Переваги головних компонент:

- 1) для зменшення обчислювальних витрат можна обирати не всі параметри, а лише кілька перших, бо вони мають найбільшу дисперсію і несуть в собі більшу частину інформації;
- 2) згідно з центральною граничною теоремою розподіл параметрів вважається нормальним, що зручно при моделюванні та обчисленнях:
 - а) фактично відсутні обмеження на параметри моделі на відміну від зваженого середнього, де сума параметрів повинна дорівнювати 1;
 - б) за побудовою випадкові величини мають нульове середнє значення та діагональну коваріаційну матрицю;
 - в) якщо нормувати параметри (перенести їх дисперсію в матрицю L), отримаємо набір незалежних випадкових величин розподілених за стандартним нормальним законом.

1.3 Задача

Позначимо множину T зображень. Кольори — відтінки сірого, що визначаються лише інтенсивністю від 0 до 1. Введемо множину I пікселів зображення. Зображення $t \in T$ є відображення з множини пікселів на множину їх значень

$$t : I \rightarrow [0; 1].$$

Інтенсивність пікселя i в зображенні t позначимо як t_i .

Взагалі кажучи, I — множина індексів матриць однакового розміру

$$I = \{\langle i, j \rangle \mid i = 1..h, j = 1..w\}.$$

Зазвичай використовуються зображення розміром від $100 \times 100 = 10^4$ пікселів. Проте сучасні камери на фотоапаратах, смартфонах та інших пристроях можуть зробити зображення площиною кілька мільйонів пікселів і більше. При використанні $2^8 = 256$ градацій сірого маємо $10^{6 \cdot 256} = 10^{1536}$ різних зображень розміром 1000×1000 , тобто неймовірно багато.

Тривимірна модель обличчя визначається набором n дійсних параметрів. Множина всіх параметрів $X = \mathbb{R}^n$. Функцією, що перетворює набір параметрів на зображення, є відображення

$$f : X \rightarrow T.$$

Введемо позначення для зображення згенерованого з певним набором параметрів x

$$f(x) = t.$$

Інтенсивність i пікселя позначимо

$$f_i(x) = t_i.$$

Поставимо Баєсову задачу розпізнавання. Для цього потрібно визначитися з функцією витрат [10]

$$W : X \times X \rightarrow \mathbb{R}.$$

Введемо множину стратегій розпізнавання Q як функцій, які кожному $t \in T$

ставлять у відповідність параметри, з якими було згенеровано обличчя на даному зображенні

$$Q = X^T.$$

Стратегію $q \in Q$, яка для зображення t дає результат x , позначимо

$$q(t) = x.$$

Математичне очікування функції витрат для даного вирішального правила q як функції випадкової величини x за умови, що було пред'явлено зображення t , називається Баєсовим ризиком [11]

$$R(q) = \sum_{t \in T} \sum_{x \in X} \mathbb{P}(x, q(t)) \cdot W(x, q(t)).$$

У випадку неперервного розподілу параметрів x

$$R(q) = \sum_{t \in T} \int_{x \in X} p(x, q(t)) \cdot W(x, q(t)) dx.$$

Задача — знайти таке вирішальне правило q , яке мінімізує Баєсів ризик

$$q^* = \arg \min_{q \in Q} R.$$

1.3.1 Бінарна функція витрат

Досить розповсюдженою, проте зазвичай неприродною є бінарна штрафна функція

$$W(x, x') = \mathbb{1}(x \neq x').$$

Оберемо стратегію q^* , що мінімізує математичне очікування цієї функції витрат

$$\begin{aligned} q^*(t) &= \arg \min_{x'} \left\{ \sum_{x \in X} \mathbb{P}(x | t) \cdot \mathbb{1}(x \neq x') \right\} = \\ &= \arg \min_{x'} \left\{ \sum_{x \in X} \mathbb{P}(x | t) - \sum_{x \in X} \mathbb{P}(x | t) \cdot \mathbb{1}(x = x') \right\} = \\ &= \arg \min_{x'} \{1 - \mathbb{P}(x' | t)\}. \end{aligned}$$

В результаті

$$q^*(t) = \arg \max_x \mathbb{P}(x | t).$$

Отже, якщо використовується бінарна функція витрат, потрібно обирати найбільш ймовірний варіант. Така задача може бути розумною, коли є небагато різних варіантів відповіді. Проте в даному випадку відповідь — набір з сотень дійсних чисел. Аналітичного виразу для розрахування f немає, отже доведеться скористатися чисельними методами, які не дадуть точної відповіді.

Очевидно, що для неперервного випадку така функція зовсім не підходить, тому що інтеграл

$$\int_{x \in X} \mathbb{1}(x \neq x') \cdot p(x | t) dx = 1, \quad \forall t \in T, \quad \forall x' \in X.$$

Тобто майже ніде немає вірної відповіді, бо майже всюди сплачується штраф.

1.3.2 Інтервальна функція витрат

Більш загальним варіантом бінарної штрафної функції є індикатор неналежності дійсного параметру x деякій δ -околиці обраного параметру x'

$$W(x, x') = \mathbb{1}(x \notin \delta(x')).$$

Оберемо стратегію, що мінімізує математичне очікування цієї функції витрат

$$\begin{aligned} q^*(t) &= \arg \min_{x'} \left\{ \sum_{x \in X} \mathbb{P}(x | t) \cdot \mathbb{1}(x \notin \delta(x')) \right\} = \\ &= \arg \min_{x'} \left\{ 1 - \sum_{x \in X} \mathbb{P}(x | t) \cdot \mathbb{1}(x \in \delta(x')) \right\} \end{aligned}$$

Для дискретного розподілу маємо

$$q^*(t) = \arg \max_{x'} \sum_{x \in \delta(x')} \mathbb{P}(x | t).$$

У випадку неперервного розподілу

$$q^*(t) = \arg \max_{x'} \int_{x \in \delta(x')} p(x | t) dx.$$

1.3.3 Різниця моделей

Розглянемо більш природню функцію витрат — квадрат евклідової відстані між точками дійсної та обраної моделі.

Введемо множину вершин обличчя V . Кожна вершина має певні координати в тривимірному просторі \mathbb{R}^3 . Модель обличчя — відображення, яке кожній вершині v ставить у відповідність її координати

$$M : V \rightarrow \mathbb{R}^3.$$

Породжувальна модель обличчя — відображення, яке кожному набору параметрів x ставить у відповідність модель m

$$G : X \rightarrow M.$$

Координати g вершини v моделі згенерованої з параметрами x позначимо

$$G_v(x) = g.$$

Координати кожної вершини v породжувальної моделі отримуються шляхом перемноження компонент параметру x на відповідний коефіцієнт λ^v отриманий за допомогою методу головних компонент та додавання результату до середнього положення поточної вершини

$$G_v(x) = g_0^v + \sum_{i \in 1}^n \lambda_i^v \cdot x_i, \quad v \in V.$$

Функція витрат має вигляд

$$\begin{aligned}
 W(x, x') &= \|G(x) - G(x')\|^2 = \sum_{v \in V} [G_v(x) - G_v(x')]^2 = \\
 &= \sum_{v \in V} \sum_{p \in P} [\lambda_p^v \cdot (x_p - x'_p)]^2 = \sum_{p \in P} \left\{ (x_p - x'_p)^2 \cdot \sum_{v \in V} (\lambda_p^v)^2 \right\} = \\
 &= \left| \beta_p^2 = \sum_{v \in V} (\lambda_p^v)^2 \right| = \sum_{p \in P} \beta_p^2 \cdot (x_p - x'_p)^2.
 \end{aligned}$$

Оберемо стратегію q^* , що мінімізує математичне очікування цієї функції витрат

$$q^*(t) = \arg \min_{x'} \left\{ \sum_{x \in X} \left[\mathbb{P}(x | t) \cdot \sum_{i=1}^n \beta_i^2 \cdot (x'_i - x_i)^2 \right] \right\}.$$

Щоб мінімізувати неперервну функцію від параметрів x'_i , можна взяти по них похідну

$$\frac{\partial \sum_{x \in X} \left[\mathbb{P}(x | t) \cdot \sum_{i=1}^n \beta_i^2 \cdot (x'_i - x_i)^2 \right]}{\partial x'_i} = 2 \cdot \sum_{x \in X} \mathbb{P}(x | t) \cdot \beta_i^2 \cdot (x'_i - x_i), \quad i = 1..n$$

та прирівняти до нуля

$$\sum_{x \in X} \mathbb{P}(x | t) \cdot (x'_i - x_i) = 0, \quad i = 1..n.$$

Значення компоненти

$$x'_i = \frac{\sum_{x \in X} \mathbb{P}(x | t) \cdot x_i}{\sum_{x \in X} \mathbb{P}(x | t)} = \sum_{x \in X} \mathbb{P}(x | t) \cdot x_i, \quad i = 1..n.$$

Результуюча стратегія

$$q^*(t) = \sum_{x \in X} x \cdot \mathbb{P}(x | t).$$

У випадку неперервного розподілу ймовірностей

$$q^*(t) = \int_{x \in X} x \cdot p(x | t) dx.$$

1.3.4 Різниця параметрів

Розглянемо більш просту функцію витрат — квадрат евклідової норми різниці між дійсними та обраними параметрами моделі зображеного обличчя

$$W(x, x') = \|x - x'\|^2 = \sum_{p \in P} (x_p - x'_p)^2.$$

Оберемо стратегію q^* , що мінімізує математичне очікування цієї функції витрат

$$q^*(t) = \arg \min_{x'} \left\{ \sum_{x \in X} \left[\mathbb{P}(x | t) \cdot \sum_{i=1}^n (x'_i - x_i)^2 \right] \right\}.$$

Маємо мінімізацію неперервної функції від параметрів x'_i , отже можемо взяти по них похідну

$$\frac{\partial \sum_{x \in X} \left[\mathbb{P}(x | t) \cdot \sum_{i=1}^n (x'_i - x_i)^2 \right]}{\partial x'_i} = 2 \cdot \sum_{x \in X} \mathbb{P}(x | t) \cdot (x'_i - x_i), \quad i = 1..n$$

та прирівняти до нуля

$$\sum_{x \in X} \mathbb{P}(x | t) \cdot (x'_i - x_i) = 0, \quad i = 1..n.$$

Значення компоненти

$$x'_i = \frac{\sum_{x \in X} \mathbb{P}(x | t) \cdot x_i}{\sum_{x \in X} \mathbb{P}(x | t)} = \sum_{x \in X} \mathbb{P}(x | t) \cdot x_i, \quad i = 1..n.$$

Результуюча стратегія

$$q^*(t) = \sum_{x \in X} x \cdot \mathbb{P}(x | t).$$

У випадку неперервного розподілу ймовірностей

$$q^*(t) = \int_{x \in X} x \cdot p(x | t) dx.$$

Отримана та ж стратегія, що мінімізує математичне очікування суми квадратів різниць координат вершин дійсної та обраної моделі обличчя. Тобто це вирішувальне правило розв'язує обидві задачі.

1.4 Розв'язок

1.4.1 Бінарна функція витрат

Розглянемо функцію витрат, за якої вірним є лише один набір параметрів, а за всі інші сплачується штраф 1.

Щоб задача мала сенс, дискретизуємо простір параметрів X . Введемо не-

велике δx таке, щоб ймовірність того, що значення потрапляє в рамки гіперкубу $\left[x - \frac{\delta x}{2}; x + \frac{\delta x}{2}\right]$, де

$$\left(x \pm \frac{\delta x}{2}\right)_i = x_i \pm \frac{\delta x}{2}, \quad i = 1..n,$$

приблизно дорівнювала добутку щільності розподілу на об'єм цього гіперкубу

$$\mathbb{P}\left(\xi \in \left[x - \frac{\delta x}{2}; x + \frac{\delta x}{2}\right]\right) \approx p(x) \cdot \delta x^n.$$

Далі треба розбити простір на гіперкуби зі стороною δx і вважати, що коли величина потрапляє на територію певного гіперкубу, то вона дорівнює значенню в його центрі. Позначимо

$$\mathbb{P}_I(x | t) = \mathbb{P}_I(\xi = x | t) = \mathbb{P}\left(\xi \in \left[x - \frac{\delta x}{2}; x + \frac{\delta x}{2}\right] \mid t\right) \approx p(x | t) \cdot \delta x^n.$$

Вважаємо, що на даному зображенні t присутній нормальний шум з невідомою дисперсією σ_t^2 . Тоді ймовірність того, що дане зображення було отримано саме з параметрами x

$$\mathbb{P}_I(x | t) = \delta x^n \cdot \prod_{i \in I} \frac{\exp\left\{-\frac{(t_i - f_i(x))^2}{2 \cdot \sigma_t^2}\right\}}{\sqrt{2 \cdot \pi \cdot \sigma_t^2}}.$$

Коли з контексту буде зрозуміло, якому саме зображенню належить дана дисперсія, індекс t не будемо використовувати.

Максимізуємо логарифм ймовірності, тому що це зручніше, ніж максими-

зація добутку кількох десятків тисяч або мільйонів значень

$$\ln \mathbb{P}_I(x | t) = \ln \delta x^n + \sum_{i \in I} \left\{ -\frac{(t_i - f_i(x))^2}{2 \cdot \sigma^2} - \frac{\ln 2 + \ln \pi + 2 \cdot \ln \sigma}{2} \right\} \rightarrow \max.$$

Позбуваємося константного доданку та помножимо на подвоєну ненульову дисперсію

$$\sum_{i \in I} (t_i - f_i(x))^2 \rightarrow \min.$$

Бачимо, що мінімізація суми квадратів різниць між дійсним та згенерованим зображенням розв'язує задачу з бінарною функцією втрат та гаусовим шумом на зображенні без інших додаткових умов, які буде розглянуто далі.

Введемо множину пікселів $F \subset I$, які на зображенні $f(x)$ належать обличчю. Тоді суму можна розбити на дві

$$\sum_{i \in I} (t_i - f_i(x))^2 = \sum_{i \in F} (t_i - f_i(x))^2 + \sum_{i \in I \setminus F} (t_i - f_i(x))^2.$$

Рахуємо вибірккову дисперсію для тієї частини зображення, де зображено обличчя

$$\overline{\sigma_F^2} = \frac{\sum_{i \in F} (t_i - f_i(x))^2}{|F| - 1}.$$

Екстраполюємо це значення на все зображення

$$\overline{\sigma_F^2} \approx \frac{\sum_{i \in I} (t_i - f_i(x))^2}{|I| - 1}.$$

Тоді вираз, який треба мінімізувати, можна представити як

$$\sum_{i \in I} (t_i - f_i(x))^2 \approx (|I| - 1) \cdot \overline{\sigma_F^2} \rightarrow \min.$$

Оскільки розмір зображення фіксований і його зменшити не вийде, потрібно зменшити вибірккову дисперсію на пікселях обличчя

$$\overline{\sigma_F^2} = \frac{\sum_{i \in F} (t_i - f_i(x))^2}{|F| - 1} \rightarrow \min.$$

1.4.2 Різниця параметрів з урахуванням їх гаусового розподілу

Вважаємо, що на даному зображенні t присутній нормальний шум з невідомою дисперсією σ_t^2 . Ймовірність того, що зображення моделі з конкретними параметрами x є очищеним від шумів зображенням t

$$\mathbb{P}_I(x | t) = \delta x^n \cdot \prod_{i \in I} \frac{\exp \left\{ -\frac{(t_i - f_i(x))^2}{2 \cdot \sigma_t^2} \right\}}{\sqrt{2 \cdot \pi \cdot \sigma^2}}.$$

Відомо, що параметри x — набори коефіцієнтів нормованих головних компонент, тобто мають стандартний гаусовий розподіл. Ймовірність того, що було згенеровано саме такий набір

$$\mathbb{P}_X(x | t) = \delta x^n \cdot \prod_{i=1}^n \frac{\exp \left(-\frac{x_i^2}{2} \right)}{\sqrt{2 \cdot \pi}}.$$

Ймовірність того, що дане зображення t було отримано саме з параметрами x , є добутком розглянутих ймовірностей

$$\mathbb{P}(x | t) = \mathbb{P}_I(x | t) \cdot \mathbb{P}_X(x | t) = \delta x^{2 \cdot n} \cdot \prod_{i \in I} \frac{\exp \left\{ -\frac{(t_i - f_i(x))^2}{2 \cdot \sigma_t^2} \right\}}{\sqrt{2 \cdot \pi \cdot \sigma_t^2}} \cdot \prod_{i=1}^n \frac{\exp \left(-\frac{x_i^2}{2} \right)}{\sqrt{2 \cdot \pi}}.$$

Коли з контексту буде зрозуміло, якому саме зображенню належить дана дисперсія, індекс t не будемо використовувати.

Винесемо константи з добутків та позначимо

$$c_t = (2 \cdot \pi)^{-\frac{w \cdot h + n}{2}} \cdot \sigma_t^{-w \cdot h}.$$

Ймовірність приймає вигляд

$$\mathbb{P}(x | t) = c_t \cdot \delta x^{2 \cdot n} \cdot \exp \left\{ -\frac{\|t - f(x)\|^2}{2 \cdot \sigma^2} \right\} \cdot \exp \left\{ -\frac{\|x\|^2}{2} \right\}.$$

Стратегія розпізнавання

$$q^*(t) = c_t \cdot \delta x^{2 \cdot n} \cdot \sum_{x \in X} x \cdot \exp \left\{ -\frac{\|t - f(x)\|^2}{2 \cdot \sigma^2} \right\} \cdot \exp \left\{ -\frac{\|x\|^2}{2} \right\}.$$

У неперервному випадку сума змінюється на інтеграл та зникають об'єми гіперкубів

$$q^*(t) = c_t \cdot \int_{x \in X} x \cdot \exp \left\{ -\frac{\|t - f(x)\|^2}{2 \cdot \sigma^2} \right\} \cdot \exp \left\{ -\frac{\|x\|^2}{2} \right\} dx.$$

Оскільки σ^2 невідома, її можна оцінити за відомою формулою оптимальної

оцінки дисперсії

$$\overline{\sigma^2} = \sum_{x \in X} \frac{\|f(x) - t\|^2}{w \cdot h \cdot n - 1}.$$

1.5 Метод Монте-Карло

Оскільки функція f , що дає зображення t для даного набору параметрів x , є складно влаштованою, вона не представлена в явному вигляді. Інтегрування виразу, що містить цю функцію, не може бути проведено аналітично. Метод Монте-Карло — чисельний метод, що підходить до розв’язку даної задачі.

Треба підрахувати інтеграл

$$q^*(t) = c_t \cdot \int_{x \in X} x \cdot \exp \left\{ -\frac{\|t - f(x)\|^2}{2 \cdot \sigma^2} \right\} \cdot \exp \left\{ -\frac{\|x\|^2}{2} \right\} dx,$$

який є математичним очікуванням функції стандартного гаусового n -вимірного вектора

$$q^*(t) = (2 \cdot \pi \cdot \sigma^2)^{-\frac{w \cdot h}{2}} \cdot M_{\xi} \left[\xi \cdot \exp \left\{ -\frac{\|t - f(\xi)\|^2}{2 \cdot \sigma^2} \right\} \right], \quad \xi_i \sim \mathcal{N}(0, 1).$$

Внесемо все в експоненту для полегшення машинних обчислень

$$q^*(t) = M_{\xi} \left[\frac{\xi}{|\xi|} \cdot \exp \left\{ \ln |\xi| - \frac{\|t - f(\xi)\|^2}{2 \cdot \sigma^2} - \frac{w \cdot h}{2} \cdot (\ln 2 + \ln \pi + \ln \sigma^2) \right\} \right].$$

Для отримання оцінки інтегралу треба згенерувати N векторів з n незале-

жних випадкових величин, що мають стандартний нормальний розподіл

$$\xi^{(i)} = \langle \xi_1^{(i)}, \xi_2^{(i)}, \dots, \xi_n^{(i)} \rangle, \quad \xi_j^{(i)} \sim \mathcal{N}(0, 1).$$

Для кожного вектору розрахувати значення підінтегрального виразу

$$Q^{(i)} = \frac{\xi^{(i)}}{|\xi^{(i)}|} \cdot \exp \left\{ \ln |\xi^{(i)}| - \frac{\|t - f(\xi^{(i)})\|^2}{2 \cdot \sigma^2} - \frac{w \cdot h}{2} \cdot (\ln 2 + \ln \pi + \ln \sigma^2) \right\}.$$

Оцінкою інтегралу буде середнє значення

$$\bar{Q}_N = \frac{\sum_{i=1}^N \hat{Q}^{(i)}}{N}.$$

Визначимо оптимальне значення N . Згадаємо центральну граничну теорему

$$\sqrt{N} \cdot \frac{\bar{Q}_N - M(Q)}{\sqrt{D(Q)}} \Rightarrow \mathcal{N}(0, 1).$$

Для певного $z_\gamma > 0$

$$\mathbb{P} \left(\sqrt{N} \cdot \frac{\bar{Q}_N - M(Q)}{\sqrt{D(Q)}} \leq z_\gamma \right) = \Phi(z_\gamma),$$

де Φ — інтегральна функція стандартного гаусового розподілу. Нас цікавить ймовірність

$$\mathbb{P} \left(-z_\gamma \leq \sqrt{N} \cdot \frac{\bar{Q}_N - M(Q)}{\sqrt{D(Q)}} \leq z_\gamma \right) = \Phi(z_\gamma) - \Phi(-z_\gamma).$$

Використаємо модуль для перевірки входження виразу в довірчий інтервал та скористаємося симетричністю гаусового розподілу

$$\mathbb{P} \left(\left| \sqrt{N} \cdot \frac{\bar{Q}_N - M(Q)}{\sqrt{D(Q)}} \right| \leq z_\gamma \right) = 2 \cdot \Phi(z_\gamma) - 1.$$

Поділимо обидві частини нерівності на модуль середнього значення виборки

$$\mathbb{P} \left(\left| \sqrt{N} \cdot \frac{\bar{Q}_N - M(Q)}{\bar{Q}_N \cdot \sqrt{D(Q)}} \right| \leq \frac{z_\gamma}{|\bar{Q}_N|} \right) = 2 \cdot \Phi(z_\gamma) - 1.$$

Позначимо відносну похибку

$$\varepsilon = \left| \frac{\bar{Q}_N - M(Q)}{\bar{Q}_N} \right|$$

та перепишемо вираз

$$\mathbb{P} \left(\left| \sqrt{N} \cdot \frac{\varepsilon}{\sqrt{D(Q)}} \right| \leq \frac{z_\gamma}{|\bar{Q}_N|} \right) = 2 \cdot \Phi(z_\gamma) - 1.$$

Перенесемо все окрім кореню від кількості спроб в праву частину нерівності

$$\mathbb{P} \left(\left| \sqrt{N} \right| \leq \left| \frac{z_\gamma \cdot \sqrt{D(Q)}}{\varepsilon \cdot \bar{Q}_N} \right| \right) = 2 \cdot \Phi(z_\gamma) - 1$$

та піднесемо обидві частини нерівності до квадрату

$$\mathbb{P} \left(N \leq \frac{z_\gamma^2 \cdot D(Q)}{\varepsilon^2 \cdot \bar{Q}_N^2} \right) = 2 \cdot \Phi(z_\gamma) - 1.$$

Перепозначимо отриману ймовірність

$$\mathbb{P} \left(N \leq \frac{z_\gamma^2 \cdot D(Q)}{\varepsilon^2 \cdot \overline{Q}_N^2} \right) = \gamma.$$

Щоб виразити z_γ , потрібно скористатися квантилем нормального розподілу

$$\Phi^{-1} \left(\frac{\gamma + 1}{2} \right) = z_\gamma.$$

Щоб відносна похибка обчислення математичного очікування методом Монте-Карло не перевищувала ε з ймовірністю γ і вище, необхідна та достатня кількість ітерацій рахується за формулою

$$N = \left\lceil \frac{z_\gamma^2 \cdot D(Q)}{\varepsilon^2 \cdot \overline{Q}_N^2} \right\rceil, \quad z_\gamma = \Phi^{-1} \left(\frac{\gamma + 1}{2} \right). \quad (1.1)$$

Коли дисперсія отриманої випадкової величини Q невідома, використовується її незміщена оцінка

$$\tilde{Q}_N = \frac{\sum_{i=1}^N \left(\hat{Q}^{(i)}(x) \right)^2 - \overline{Q}_N^2}{N - 1}.$$

Формула (1.1) використовується лише для перевірки того, чи дає наявна вибірка з N елементів відповідь з вказаною похибкою. Спочатку необхідно дати алгоритму “розігрітись” і не порівнювати значення N з необхідною кількістю кроків. Також немає необхідності у перевірці відповідності значення N на кожній ітерації, особливо якщо це займає багато часу — достатньо робити перерахунок кожні 100 або 1000 кроки в залежності від інтегралу.

2 ПРАКТИЧНІ РЕЗУЛЬТАТИ

3 ОХОРОНА ПРАЦІ

ВИСНОВКИ

В результаті виконання роботи вдалося.

ПЕРЕЛІК ПОСИЛАНЬ

1. A 3D Face Model for Pose and Illumination Invariant Face Recognition / P. Paysan, R. Knothe, B. Amberg et al. // *Proceedings of the 6th IEEE International Conference on Advanced Video and Signal based Surveillance (AVSS) for Security, Safety and Monitoring in Smart Environments*. — 2009.
2. Blanz, V. A morphable model for the synthesis of 3D faces / V. Blanz, T. Vetter // *Proceedings of the 26th annual conference on Computer graphics and interactive techniques*. — 1999. — Pp. 187–194.
3. Jones, M. J. Multidimensional morphable models / M. J. Jones, T. Poggio. — 1998. — Jan. — Pp. 683–688.
4. Blanz, V. Face Identification across Different Poses and Illuminations with a 3D Morphable Model / V. Blanz, S. Romdhani, T. Vetter // *Automatic Face and Gesture Recognition, 2002. Proceedings. Fifth IEEE International Conference on*. — 2002. — Pp. 192–197.
5. Blanz, V. Face recognition based on fitting a 3D morphable model / V. Blanz, T. Vetter // *IEEE Transactions on Pattern Analysis and Machine Intelligence*. — 2003. — Sept. — Vol. 25, no. 9. — Pp. 1063–1074.
6. Tyshchenko, M. 3D Reconstruction of Human Face Based on Single or Several Images / M. Tyshchenko // *Управляющие системы и машины*. — 2011. — № 2. — С. 79–85.
7. Rossi, Francesca. Handbook of Constraint Programming (Foundations of Artificial Intelligence) / Francesca Rossi, Peter van Beek, Toby Walsh. — New York, NY, USA: Elsevier Science Inc., 2006. — P. 978.

8. Amberg, Brian. Optimal Step Nonrigid ICP Algorithms for Surface Registration. / Brian Amberg, Sami Romdhani, Thomas Vetter // *2007 IEEE Conference on Computer Vision and Pattern Recognition*. — 2007.
9. Айвазян, С.А. Прикладная статистика: Классификация и снижение размерности : Справочное издание / С.А. Айвазян. — М.: Финансы и статистика, 1989. — 606 с.
10. Berger, J.O. Statistical Decision Theory: Foundations, Concepts, and Methods / J.O. Berger // Springer Series in Statistics. — Springer New York, 1980. — P. 428.
11. Schlesinger, M.I. Ten Lectures on Statistical and Structural Pattern Recognition / M.I. Schlesinger, V. Hlavác // *Computational Imaging and Vision*. — Springer Netherlands, 2002. — P. 522.